

SynthAES-PT: Um Conjunto de Dados Sintéticos para Avaliação da Aderência ao Tópico em Português Brasileiro

Maxine A. S. Gois¹, Joaquim E. Vivas^{1*}, Marta T. C. F. de Amorim¹, Evelin C. F. de Amorim²

¹Ifes – Instituto Federal do Espírito Santo - Campus Serra
Av. dos Sabiás, 330 - Morada de Laranjeiras, Serra – Espírito Santo – ES – Brazil

²INESC TEC – Instituto de Engenharia de Sistemas e Computadores
Porto, Portugal

{maxxennii@gmail.com, joaquimef22@gmail.com,
marta.amorim@ifes.edu.br, evelin.f.amorim@inesctec.pt}

Abstract. *Topic Adherence Assessment is a fundamental task in Automated Essay Scoring (AES), yet it remains constrained by the limited availability of high-quality datasets in Brazilian Portuguese. This paper proposes a methodology for constructing and validating a synthetic dataset specifically designed for topic adherence assessment. The methodology is based on the AES-PT corpus and leverages three Large Language Models (LLMs): Qwen, Gemini, and Mistral. The resulting dataset comprises 2,951 essays distributed across three writing quality levels (low, medium, and high). As a key contribution, the dataset employs a sentence-level annotation strategy that identifies each sentence with the proposed topic, providing a more fine-grained representation than conventional document-level labels. The dataset was validated through a combination of linguistic quality metrics and human evaluation. The results demonstrate that the proposed methodology produces a diverse, well-documented, and reliable corpus, providing a valuable resource for Natural Language Processing research on topic adherence assessment and supporting the development of educational applications in Brazilian Portuguese.*

Resumo. *A Avaliação de Aderência ao Tópico constitui uma tarefa fundamental na avaliação automática de redações, porém ainda enfrenta limitações decorrentes da escassez de datasets em português brasileiro. Este trabalho propõe uma metodologia para a construção e validação de um dataset sintético destinado a essa tarefa, utilizando o corpus AES-PT como base e três Grandes Modelos de Linguagem (LLMs): Qwen, Gemini e Mistral. O processo resultou em um conjunto de 2.951 redações distribuídas em três níveis de qualidade textual. Como diferencial, o dataset adota uma estratégia de anotação em nível de sentença, permitindo identificar o alinhamento de cada trecho ao tema proposto. A validação foi conduzida por meio de métricas linguísticas e avaliação humana. Os resultados indicam que a metodologia produz um corpus diversificado e adequadamente documentado, contribuindo para o desenvolvimento de pesquisas em Processamento de Linguagem Natural voltadas à Avaliação de Aderência ao Tópico e à disponibilização de recursos para o contexto educacional.*

1. Introdução

O avanço dos Grandes Modelos de Linguagem (*Large Language Models* - LLMs) ampliou significativamente as possibilidades de aplicação do Processamento de Linguagem Natural (PLN). Entretanto, o desempenho desses modelos em tarefas especializadas depende da disponibilidade de conjuntos de dados representativos e de qualidade. Na Avaliação de Aderência ao Tópico, que verifica se um texto permanece semanticamente relacionado ao tema proposto, essa limitação é particularmente relevante para o português brasileiro, devido à escassez de *dataset* específicos [Passero et al. 2019].

Iniciativas como AES-PT [Amorim e Veloso 2017], Essay-BR [Marinho 2021] e outros corpora brasileiros contribuíram para ampliar os recursos disponíveis para a Avaliação Automática de Redações (*Automated Essay Scoring* - AES). Entretanto, ainda existem limitações relacionadas à cobertura temática, ao balanceamento das classes, à diversidade linguística e, principalmente, à disponibilidade de anotações específicas para aderência temática. A literatura também permanece concentrada, em grande parte, em uma classificação binária entre textos dentro e fora do tópico, dificultando análises mais granulares.

Este trabalho propõe uma metodologia para construção e validação de um *dataset* sintético em português brasileiro destinado à Avaliação de Aderência ao Tópico inspirada na estratégia de alinhamento semântico proposta por Calizzano et al. (2022). A partir do corpus AES-PT, foram geradas 2.951 redações dissertativo-argumentativas utilizando diferentes LLMs e estratégias de *prompting*. As redações foram produzidas em diferentes níveis de qualidade textual, permitindo investigar a relação entre qualidade linguística e aderência temática.

As principais contribuições são: (i) uma metodologia para construção de *datasets* sintéticos voltados à Avaliação de Aderência ao Tópico; (ii) um corpus em português brasileiro com 2.951 redações; (iii) anotações semânticas em nível de sentença; (iv) validação quantitativa e humana do corpus; e (v) disponibilização pública dos dados e códigos, favorecendo a reprodutibilidade.

O restante deste artigo está organizado da seguinte forma. A Seção 2 apresenta os trabalhos relacionados. A Seção 3 descreve a metodologia de construção e validação do corpus. A Seção 4 apresenta os resultados experimentais e a validação do dataset. Por fim, a Seção 5 apresenta as conclusões e os trabalhos futuros.

2. Trabalhos Relacionados

Diversos estudos têm contribuído para o avanço da AES e da detecção de aderência ao tópico em português brasileiro. A Tabela 1 resume os principais trabalhos relacionados e suas características.

Tabela 1. Trabalhos Relacionados

Trabalho	Objetivo	Contribuição	Limitações
Passero et al. (2019)	Correção de redação por rubrica no idioma português	Corpus público com 2.164 redações do ENEM distribuídas em 111 temas	Abordaram apenas classificação binária (dentro ou fora do tópico)
Silveira, Barbosa e Mauá (2024)	Benchmark para AES	Corpus público de 3.586 redações e avaliação com BERTimbau	Não contempla avaliação de aderência ao tópico nem anotações em nível de sentença
Silva et al. (2025)	Correção de redação por rubrica no idioma português	Corpus público com 4.570 redações do ENEM	Abordaram apenas classificação binária (dentro ou fora do tópico) e <i>Dataset</i> desbalanceado

Os trabalhos existentes representam avanços relevantes para a AES em português brasileiro, especialmente pela disponibilização de corpora públicos de referência e pela investigação de abordagens baseadas em modelos de linguagem contextualizados, como os Transformers. Entretanto, esses estudos ainda apresentam limitações, principalmente em razão do desbalanceamento do corpus e da dificuldade dos modelos atuais em distinguir problemas relacionados à qualidade linguística e à aderência temática. Em particular, observa-se que modelos recentes tendem a apresentar comportamento restritivo, classificando redações com baixa qualidade técnica como fora do tópico, mesmo quando há desenvolvimento semântico compatível com a proposta de redação.

Além disso, o estado da arte permanece predominantemente concentrado em uma formulação binária da tarefa, na qual as redações são classificadas como dentro ou fora do tópico, sem contemplar categorias intermediárias ou diferentes tipos de desvios temáticos. Também são escassos os recursos que possibilitam avaliações em cenários multiclasse ou que disponibilizam anotações semânticas em nível de sentença, permitindo análises mais detalhadas da relação entre as partes constituintes do texto e o tema proposto.

Nesse contexto, este trabalho propõe a construção de um novo dataset sintético em português brasileiro voltado à análise de aderência temática em redações. Diferentemente das iniciativas anteriores, o corpus proposto explora redações geradas por múltiplos LLMs, buscando ampliar a diversidade textual e mitigar a escassez de exemplos anotados disponíveis. Além disso, o dataset contempla diferentes níveis de qualidade textual, permitindo investigar a distinção entre deficiências linguísticas, estruturais e argumentativas e a fuga ao tema. Por fim, a proposta incorpora uma estratégia de anotação semântica em nível de sentença, possibilitando uma análise

granular da aderência temática e contribuindo para o desenvolvimento de modelos mais interpretáveis para tarefas de PLN aplicadas à AES.

3. Metodologia

A construção do *dataset* foi organizada em três etapas: geração das redações sintéticas, anotação semântica e validação do corpus. A Figura 1 apresenta uma visão geral da metodologia adotada.




Figura 1. Visão geral da metodologia

3.1. Geração do Corpus Sintético

O corpus AES-PT [Amorim e Veloso 2017], composto por 1.840 redações dissertativo-argumentativas distribuídas em 96 temas, foi utilizado como fonte das propostas de redação. Para cada proposta foram considerados o comando temático e os textos motivadores.

A geração foi realizada utilizando Qwen2.5-14B-Instruct, Qwen2.5-7B-Instruct [Qwen 2024], Mistral Large [Mistral 2024], Gemini 2.5 Flash e Gemini 2.5 Flash-Lite. Os modelos foram empregados para produzir textos com diferentes níveis de qualidade. Para os modelos Qwen e Mistral, foram consideradas as categorias alta, média e baixa. Para os modelos Gemini, foram utilizadas quatro faixas associadas à escala de desempenho do ENEM: abaixo de 450, 450–650, 650–800 e acima de 800 pontos.

Os modelos executados localmente foram carregados com quantização de 4 bits. A geração utilizou estratégias de prompting, incluindo *Few-shot Prompting* e *Chain-of-Thought*, com instruções relacionadas à norma-padrão, organização textual, argumentação, repertório sociocultural e aderência ao tema, considerando os critérios de avaliação da redação do ENEM [INEP 2025].

Ao final, foram obtidas 2.951 redações sintéticas, mantendo-se a associação entre cada texto e sua respectiva proposta temática.

3.2. Anotação Semântica do Corpus Sintético

A anotação foi realizada em nível de sentença por meio de duas estratégias complementares. A primeira, denominada Anotação Binária de Aderência, classifica cada sentença como semanticamente relacionada ou não ao comando temático. Além do rótulo, os modelos geraram uma justificativa e identificaram eventos que fundamentassem a decisão. Neste trabalho, evento é definido como uma ocorrência significativa descrita no texto, envolvendo ações, estados ou acontecimentos associados a participantes e contextualizados no tempo e/ou espaço, capazes de influenciar o desenvolvimento da narrativa [Santana et al. 2023]. A estrutura resultante contém, para cada redação, as sentenças, os respectivos rótulos, os eventos identificados e as justificativas, conforme ilustrado na Figura 2.

```
{
  "frase": "A AIDS, doença que assolou o mundo na década de 1980, ainda é uma realidade presente em nossas sociedades.",
  "link": true,
  "evento": "A frase menciona a AIDS, doença que é o tema central da redação..."
}
```

Figura 2. Estrutura JSON da anotação gerada

A segunda estratégia, denominada Anotação de Alinhamento Semântico, foi aplicada às redações geradas pelos modelos Gemini. Nesse caso, o modelo produziu um mapeamento entre cada sentença da redação e as sentenças do comando temático e dos textos motivadores que apresentassem relação semântica, conforme ilustrado na Figura 3. Dessa forma, a anotação não apenas indica se uma sentença está relacionada ao tema, mas também identifica quais elementos da proposta sustentam essa relação. As duas estratégias permitem representar a aderência de maneira mais interpretável, possibilitando identificar tanto sentenças relacionadas ao tema quanto trechos que representam desvios ou divagações.

```
{
  "tema": "a-aids-nao-e-mais-a-mesma-por-que-diminuiu-o-medo-da-doenca",
  "comando_tematico": { "frases": { "0": "A Aids não é mais a mesma?", ... } },
  "textos_motivadores": { "frases": { "0": "O Ministério da Saúde ...", ... } },
  "redacao_gerada": { "0": "A Síndrome da Imunodeficiência Adquirida ...", ... },
  "mapeamento_frases": {
    "0": {
      "comando_tematico": ["0"],
      "textos_motivadores": ["0", "5"]
    },
    ...
  }
}
```

Figura 3. Estrutura JSON com mapeamento semântico

3.3. Validação do Corpus Sintético

A validação foi realizada por meio de duas abordagens complementares: análise quantitativa e avaliação humana. Na análise quantitativa, as redações sintéticas foram comparadas às redações originais utilizando métricas de diversidade lexical, complexidade lexical e subjetividade [Baayen 2001; McCarthy; Jarvis 2010; Devlin et al. 2019]. A diversidade foi avaliada por meio do *Type-Token Ratio* (TTR) e do *Measure of Textual Lexical Diversity* (MTLD), enquanto a complexidade lexical considerou o número de sílabas das palavras. A subjetividade foi estimada por meio de um modelo BERT ajustado para essa tarefa.

As métricas foram utilizadas para verificar se os textos sintéticos apresentavam características compatíveis com as redações originais e se havia diferenças coerentes entre os níveis de qualidade definidos na geração.

A avaliação humana foi realizada com uma amostra de redações sintéticas e originais. Os documentos foram apresentados de forma cega, sem identificação de sua origem, reduzindo possíveis vieses dos avaliadores. Cada documento recebeu pontuação de 0 a 5 para quatro critérios: fluência, coerência, realismo e especificidade [INEP 2025]. Posteriormente, foram calculadas média, mediana e desvio padrão das avaliações, tanto para os textos originais quanto para os sintéticos.

4. Resultados

4.1. Análise Linguística

A Tabela 2 apresenta as métricas obtidas para as redações originais e para os textos produzidos pelos modelos Gemini 2.5 Flash e Gemini 2.5 Flash-Lite [Google 2025].

Os resultados mostram valores próximos entre os textos sintéticos e o corpus original. A diversidade lexical dos textos produzidos pelos modelos Gemini apresentou valores ligeiramente inferiores aos dados originais, enquanto a complexidade lexical permaneceu próxima. A subjetividade também apresentou comportamento semelhante, com valores de 0,42 nos dois modelos Gemini e 0,44 no corpus original.

Esses resultados sugerem que os textos sintéticos preservam características linguísticas próximas às observadas nas redações de referência. As análises completas dos modelos Qwen e Mistral, bem como os scripts utilizados, estão disponíveis no repositório público¹ do projeto.

Tabela 2. Análise Linguística

Modelo/Conjunto	Métrica	Média	Desvio Padrão	Mediana
Dados Originais	Diversidade Lexical	0,61	0,06	0,62

¹<https://github.com/joaquim-gith/Datasets-Sinteticos>
https://github.com/Maxxenniii/Aderencia_ao_top-co

	Complexidade Lexical	0,30	0,05	0,30
	Subjetividade	0,44	0,05	0,44
Gemini 2.5 Flash	Diversidade Lexical	0,56	0,05	0,57
	Complexidade Lexical	0,31	0,11	0,29
	Subjetividade	0,42	0,05	0,42
Gemini 2.5 Flash-Lite	Diversidade Lexical	0,57	0,06	0,57
	Complexidade Lexical	0,29	0,11	0,31
	Subjetividade	0,42	0,05	0,42

4.2 Avaliação Humana

Para avaliar a qualidade dos dados sintéticos gerados, foi conduzido um processo de validação humana com a participação de estudantes. Inicialmente, as redações foram organizadas em grupos de 30 amostras para cada faixa de qualidade. Para os conjuntos gerados pelos modelos Gemini 2.5 Flash e Gemini 2.5 Flash-Lite, as redações foram distribuídas nas faixas de pontuação abaixo de 450, 450–650, 650–800 e 800–1000, seguindo a escala de notas do ENEM. Já para os conjuntos produzidos pelos modelos Qwen e Mistral Large, as redações foram categorizadas em três níveis de qualidade: alta, média e baixa, conforme a estratégia de geração adotada por esses modelos.

Cada grupo foi composto por redações sintéticas e suas respectivas redações originais, totalizando **15 pares de textos** (30 documentos amostrados) por conjunto avaliado. A identificação da origem dos documentos (original ou sintética) foi ocultada durante todo o processo de avaliação, de modo que os avaliadores realizassem suas análises de forma cega, minimizando a influência de vieses relacionados à procedência dos textos. A avaliação foi realizada com base em quatro critérios descritos na Tabela 3.

Tabela 3. Critérios para Validação Humana

Critério	Descrição
Fluência [Marcuschi 2008]	Clareza e naturalidade
Coerência [Koch 2015]	Encadeamento lógico
Realismo [Marcuschi 2008]	Semelhança com texto humano
Especificidade [Antunes 2010]	Precisão temática

Cada documento recebeu uma pontuação variando de 0 a 5 em cada um dos quatro critérios, utilizando uma escala do tipo Likert, na qual 0 representa desempenho inexistente e 5 corresponde ao desempenho excelente.

Após a finalização do processo de avaliação, foram calculadas as medidas de tendência central — média, mediana e moda — das pontuações atribuídas às redações originais e sintéticas. Adicionalmente, essas métricas foram calculadas de forma estratificada para cada nível de qualidade das redações sintéticas, permitindo analisar se os textos gerados pelos modelos de linguagem apresentavam características compatíveis com os rótulos de qualidade definidos durante a etapa de geração.

Para complementar a análise dos resultados foram elaborados boxplots para os conjuntos produzidos pelos modelos, apresentados na Figura 4, que possibilitam uma análise da variabilidade das avaliações atribuídas às redações originais e sintéticas. As distribuições observadas para as demais faixas e modelos de linguagem que apresentaram comportamento semelhante estão armazenadas no repositório para consulta.




Figura 4. Primeiro boxplot Gemini 2.5/Segundo Faixa Alta para Modelo Qwen

5. Conclusão e Trabalhos Futuros

Este trabalho apresentou uma metodologia para construção e validação do SynthAES-PT, um dataset sintético em português brasileiro voltado à Avaliação de Aderência ao Tópico em redações dissertativo-argumentativas. O corpus contém 2.951

redações geradas por diferentes LLMs, que permite investigar a aderência temática em nível de sentença, separando-a de problemas de qualidade textual.

A validação combinou métricas linguísticas e avaliação humana. Os resultados obtidos indicam similaridade entre características dos textos sintéticos e das redações originais, além de evidências de coerência com os níveis de qualidade definidos durante a geração. A anotação em nível de sentença constitui um diferencial do corpus, pois permite análises mais granulares da relação entre o texto produzido e a proposta de redação.

Como limitações, destaca-se a necessidade de ampliar o número de temas, gêneros textuais e estratégias de geração, bem como aprofundar a validação humana das anotações semânticas. Como trabalho futuro, pretende-se investigar uma arquitetura em três etapas: (i) geração e validação de dados semissintéticos; (ii) recuperação e seleção de uma *shortlist* de redações utilizando métodos como BM25, SPLADEv3 e BGE-M3; e (iii) classificação final utilizando a combinação de recuperação de informação e LLM (R+LLM). Essa abordagem poderá reduzir o custo computacional da inferência e ampliar a capacidade de avaliação automática da aderência temática.

6. Referências

- Amorim, Evelin; Veloso, Adriano. A multi-aspect analysis of automatic essay scoring for Brazilian Portuguese. In: Student research workshop at the 15th conference of the European chapter of the association for computational linguistics, 15, 2017, Valencia. Proceedings [...] Valencia: Association for Computational Linguistics, 2017. p. 94–102. Disponível em: <https://aclanthology.org/E17-4010/>. Acesso em: 6 ago. 2026.
- Antunes, Irlandé. Análise de Textos: Fundamentos e Práticas. São Paulo: Parábola Editorial, 2010.
- Baayen, H. R. Word Frequency Distributions. Dordrecht: Kluwer Academic Publishers, 2001.
- Calizzano, Rémi; Ostendorff, Malte; Ruan, Qian; Rehm, Georg. Generating extended and multilingual summaries with pre-trained transformers. In: Proceedings of the Thirteenth Language Resources and Evaluation Conference (LREC 2022). Marseille, France: European Language Resources Association, 2022. p. 1640–1650.
- Devlin, Jacob; Chang, Ming-Wei; Lee, Kenton; Toutanova, Kristina. BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. In: Conference of the North American chapter of the association for computational linguistics: human language technologies (NAACL-HLT), 2019, DOI: 10.18653/v1/N19-1423. Disponível em: <https://aclanthology.org/N19-1423/>. Acesso em: 24 jul. 2026.
- Google. Gemini 2.5 Models: Technical Report. Mountain View: Google, 2025.
- INEP. A redação no ENEM 2025: cartilha do participante. Brasília: Instituto Nacional de Estudos e Pesquisas Educacionais Anísio Teixeira, 2025.
- Koch, Ingedore Villaça; Elias, Vanda Maria. Ler e Compreender: os Sentidos do Texto. 3. ed. São Paulo: Contexto, 2015.

Marcuschi, Luiz Antônio. *Produção Textual, Análise de Gêneros e Compreensão*. São Paulo: Parábola Editorial, 2008.

Marinho, Jeziel C.; Anchiêta, Rafael T.; Moura, Raimundo S. Essay-BR: a Brazilian corpus of essays. arXiv, 2021. Disponível em: <https://arxiv.org/abs/2105.09156>. Acesso em: 1 jul. 2026.

McCarthy, Philip M.; Jarvis, Scott. MTL-D, vocd-D, and HD-D: A validation study of sophisticated approaches to lexical diversity assessment. *Behavior Research Methods*, New York, v. 42, n. 2, p. 381–392, 2010. DOI: 10.3758/BRM.42.2.381.

Mistral AI. Mistral Large. Paris: Mistral AI, 2024. Disponível em: <https://docs.mistral.ai/>. Acesso em: 1 jul. 2026.

Passero, Guilherme; Ferreira, Rafael; DAZZI, Rudimar Luís Scaranto. Off-topic Essay Detection: A Comparative Study on the Portuguese Language. *Revista Brasileira de Informática na Educação*, Porto Alegre, v. 27, n. 3, p. 177–190, 2019. DOI: 10.5753/rbie.2019.27.03.177.

Qwen. Qwen2.5 Technical Report. arXiv, 2024. Disponível em: <https://arxiv.org/abs/2412.15115>. Acesso em: 1 jul. 2026.

Santana, Brenda; Campos, Ricardo; Amorim, Evelin; Jorge, Alípio; Silvano, Purificação; Nunes, Sérgio. A Survey on Narrative Extraction from Textual Data. *Artificial Intelligence Review*, v. 56, n. 8, p. 8393–8435, 2023. DOI: 10.1007/s10462-022-10338-7.

Silva, Joyce M.; Anchiêta, Rafael T.; De Sousa, Rogério F.; Moura, Raimundo S. Investigating Methods to Detect Off-topic Essays. In: *Brazilian conference on intelligent systems (BRACIS)*, 34., 2024, p. 346–3. ISSN 2643-6264.

Silveira, Igor Cataneo; Barbosa, André; Mauá, Denis Deratani. A New Benchmark for Automatic Essay Scoring in Portuguese. In: *International conference on computational processing of Portuguese language (PROPOR)*, 16, 2024, Santiago de Compostela, Espanha. *Proceedings of the 16th International Conference on Computational Processing of Portuguese*. Stroudsburg: Association for Computational Linguistics, 2024. p. 228–237. Disponível em: <https://aclanthology.org/2024.propor-1.23/>. Acesso em: 1 jul. 2026.